# Studi Ablasi RNN, LSTM, dan GRU dibandingkan ANN untuk Prediksi Trafik Seluler Kota Milan

Helsa Anastasya
NIM: 124400009
Kelas RA
Teknik Telekomunikasi, ITERA

***Ringkasan*—Penelitian ini mengadu empat model, yaitu ANN, RNN, LSTM, dan GRU, untuk memprediksi trafik internet seluler per jam pada dataset Telecom Italia di Kota Milan, dengan kawasan Duomo dan Corso Como sebagai lokasi uji. Peneliti memvariasikan tujuh faktor ablasi: panjang jendela, ukuran hidden, jumlah lapisan, learning rate, kelompok fitur, batch size, dan early stopping patience. Tiap konfigurasi dijalankan dengan tiga random seed, sehingga tercatat 348 percobaan, lalu MAE, RMSE, dan MAPE dihitung pada data validasi maupun data pengujian.**

**Pada konfigurasi acuan di Duomo, RNN mencatat validation MAE terendah, yaitu 206,1. GRU menyusul tipis di angka 207,5, sedangkan LSTM berada di 230,5 dan ANN paling belakang dengan 248,9. Ketika peneliti menggabungkan hyperparameter terbaik dari setiap faktor ablasi, validation MAE ANN turun menjadi 212,4, tetapi ketiga model rekuren tidak ikut membaik dan skor validasinya tidak melampaui konfigurasi acuan masing-masing.**

**Artinya, memilih hyperparameter satu per satu tidak menjamin kombinasi akhirnya optimal, dan arsitektur yang lebih kompleks belum tentu menghasilkan prediksi yang lebih akurat.**

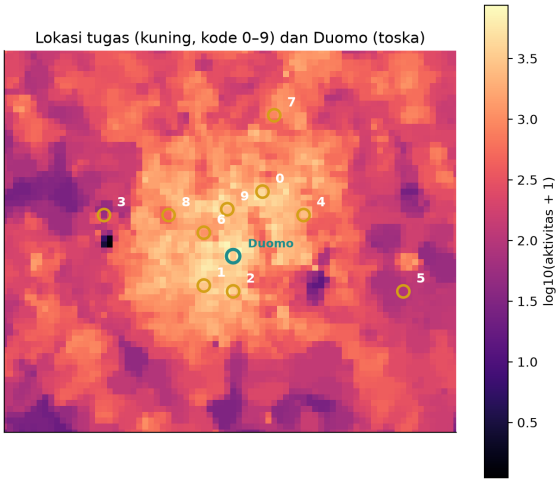
***Index Terms*—prediksi trafik seluler, ANN, RNN, LSTM, GRU, studi ablasi, hyperparameter**

## I. Pendahuluan

Operator telekomunikasi membutuhkan prediksi trafik internet seluler untuk mengatur kapasitas jaringan, mengantisipasi lonjakan permintaan, dan menjaga kualitas layanan. Trafik itu sendiri tidak berperilaku sederhana: pemakaiannya berubah menurut jam, hari, dan kegiatan pengguna. Karena itu, metode prediksi harus sanggup menangkap hubungan nonlinier sekaligus ketergantungan antarwaktu.

Penelitian ini mengadu Artificial Neural Network (ANN) dengan tiga arsitektur jaringan saraf rekuren, yaitu Recurrent Neural Network (RNN), Long Short-Term Memory (LSTM) [1], dan Gated Recurrent Unit (GRU) [2]. ANN berperan sebagai pembanding nonrekuren, sementara RNN, LSTM, dan GRU memang dirancang untuk memproses data sekuensial. Rancangan keempatnya berbeda, jadi wajar bila hasil prediksi trafik seluler dari data historis ikut berbeda.

Untuk mencari tahu faktor apa yang menggerakkan kinerja prediksi, penelitian ini menjalankan studi ablasi pada panjang jendela masukan, ukuran hidden, jumlah lapisan, learning rate, kelompok fitur, batch size, dan early stopping patience. Studi ablasi mengubah satu faktor sambil menahan faktor lain di konfigurasi acuan, sehingga pengaruh faktor tersebut terlihat tersendiri.




Gambar 1. Rata-rata aktivitas internet per kotak di Milan. Lingkaran kuning: lokasi tugas (kode 0–9); lingkaran toska: Duomo.

Penelitian ini menyumbang tiga hal: (1) perbandingan performa ANN, RNN, LSTM, dan GRU pada prediksi trafik internet seluler per jam; (2) analisis sensitivitas performa terhadap tujuh faktor ablasi dengan tiga random seed; dan (3) evaluasi kombinasi hyperparameter pilihan beserta generalisasinya dari lokasi Duomo ke Corso Como.

## II. Data dan Metode

### A. Dataset

Data berasal dari Telecom Italia Big Data Challenge, yang merekam aktivitas telekomunikasi di Kota Milan, Italia [3]. Penelitian ini memakai versi agregasi per jam yang sudah diolah pada dataset workshop [4].

Model memprediksi volume aktivitas internet (*net*). Sebagai fitur tambahan, tersedia aktivitas panggilan (*call*), SMS, dan informasi waktu dalam bentuk sinus dan kosinus untuk jam serta hari. Fitur waktu ini membantu model mengenali pola pemakaian jaringan yang berulang tiap hari dan tiap minggu.

Eksperimen utama berjalan di kawasan Duomo (kode kotak 5060). Corso Como (kode lokasi kelompok 9, grid 5859) menjadi lokasi uji generalisasi: apakah konfigurasi yang dipilih dari data Duomo tetap bekerja baik di tempat dengan karakter trafik yang berbeda.

Tabel I
KONFIGURASI ACUAN

| Hyperparameter | Nilai acuan |
|---|---|
| Panjang jendela $W$ | 24 jam |
| Horizon | 1 jam |
| Ukuran hidden | ANN 32, RNN 68, LSTM 33, GRU 38 |
| Jumlah lapisan | ANN 2, rekuren 1 |
| Fitur | net, call, sms, jam, hari (7) |
| Optimizer, *learning rate* | Adam, $10^{-3}$ |
| *Batch size* | 64 |
| *Early stopping* | *patience* 30, maks. 300 epoch |

### B. Pembagian Data dan Praproses

Data dibagi secara kronologis supaya sifat deret waktunya tetap utuh. Pelatihan memakai 11 November sampai 8 Desember 2013, validasi 9–15 Desember 2013, dan pengujian 16–22 Desember 2013. Periode 4–10 November tidak ikut dilatih; ia hanya menyediakan konteks historis untuk membentuk jendela masukan di awal data. Periode Natal sengaja masuk agar model teruji pada kondisi trafik yang berbeda.

Praproses terdiri atas pemilihan fitur, standardisasi, dan pembentukan jendela pengamatan (*windowing*). Tiap jendela berisi $W$ pengamatan per jam, yang model pakai untuk memprediksi trafik pada horizon tertentu. Konfigurasi acuan menetapkan $W = 24$ jam dengan horizon satu jam.

Standardisasi hanya menghitung statistik dari data pelatihan, sehingga informasi dari data validasi dan pengujian tidak bocor ke model (*data leakage*). Data juga tidak diacak: urutan waktu menjaga hubungan temporal, dan evaluasi selalu jatuh pada periode setelah data pelatihan.

### C. Model dan Konfigurasi Acuan

Empat arsitektur masuk perbandingan: ANN, RNN, LSTM, dan GRU. ANN menerima jendela masukan yang sudah diratakan menjadi satu vektor, sedangkan RNN, LSTM, dan GRU membaca data langkah demi langkah sehingga bisa menangkap ketergantungan temporal.

Konfigurasi acuan memakai jendela 24 jam, horizon prediksi satu jam, dan seluruh kelompok fitur. Optimizernya Adam dengan learning rate 0,001, batch size 64, dropout 0, dan loss MSE. Pelatihan berhenti lebih awal bila tidak ada perbaikan selama 30 epoch (patience 30), dengan batas maksimum 300 epoch.

Ukuran hidden berbeda untuk tiap arsitektur: 32 pada ANN, 68 pada RNN, 33 pada LSTM, dan 38 pada GRU. Angka-angka itu membuat jumlah parameter keempat model berdekatan, yakni 6.497 untuk ANN, 5.305 untuk RNN, 5.578 untuk LSTM, dan 5.397 untuk GRU. ANN punya dua lapisan tersembunyi, sementara ketiga model rekuren hanya satu. Untuk melihat seberapa konsisten hasil pelatihan, setiap konfigurasi berjalan dengan tiga random seed: 0, 1, dan 2.

### D. Protokol Ablasi dan Evaluasi

Ablasi berjalan satu faktor pada satu waktu (*one-factor-at-a-time*): satu hyperparameter berubah, sedangkan sisanya tetap di konfigurasi acuan. Bagian A memuat lima faktor wajib, yaitu panjang jendela (6, 12, 24, 48, 168 jam), ukuran hidden (16, 32, 64, 128), jumlah lapisan (1, 2, 3), learning rate (0,0001; 0,001; 0,01), dan kelompok fitur (net, net+call+sms, net+waktu, semua).

Bagian B menguji dua faktor pilihan: batch size (16, 64, 256) dan early stopping patience (10, 30, 60). ANN, RNN, LSTM, dan GRU menjalani semua konfigurasi itu, masing-masing dengan tiga random seed (0, 1, 2). Totalnya 348 percobaan, sudah termasuk konfigurasi acuan, kombinasi terpilih, dan pengujian generalisasi lokasi.

Mean Absolute Error (MAE), Root Mean Squared Error (RMSE), dan Mean Absolute Percentage Error (MAPE) dihitung pada skala asli data, lalu dilaporkan sebagai rata-rata dan simpangan baku dari tiga seed. Peneliti memilih hyperparameter dengan rata-rata MAE validasi terendah dan sengaja tidak melihat data pengujian, agar pemilihan model tidak bias.

Seluruh eksperimen berjalan di PyTorch pada CPU dengan mode eksperimen penuh (`CEPAT=False`). Catatan notebook menunjukkan total waktu pelatihan 361,9 menit, atau sekitar 6,03 jam.

Tabel II
PERBANDINGAN PERFORMA KONFIGURASI ACUAN DI DUOMO

| Model | Val MAE | Test MAE |
|---|---|---|
| ANN | 248,9 | 309,9 |
| RNN | **206,1** | **229,6** |
| LSTM | 230,5 | 273,6 |
| GRU | 207,5 | 237,2 |

## III. HASIL

### A. Baseline Naif dan Acuan

Sebagai pembanding, penelitian ini memakai tiga metode prediksi naif: nilai satu jam sebelumnya, satu hari sebelumnya, dan satu minggu sebelumnya. Pada horizon satu jam, naif minggu sebelumnya mencatat test MAE 467,6, lebih rendah daripada naif kemarin (552,2) dan nilai terakhir (600,9).

Tabel I memperlihatkan hasil konfigurasi acuan. RNN menghasilkan galat terendah, dengan validation MAE 206,1 dan test MAE 229,6. GRU menyusul di posisi kedua dengan test MAE 237,2, lalu LSTM di 273,6 dan ANN di 309,9. Keempat model mengalahkan ketiga baseline naif pada horizon satu jam; ANN, yang terlemah di antara mereka, masih unggul 157,7 poin dari naif minggu sebelumnya.

### B. Ablasi Wajib

Ablasi pada lima faktor utama ini mengukur pengaruhnya terhadap kinerja ANN, RNN, LSTM, dan GRU. Nilai terbaik di tiap faktor dipilih dari rata-rata validation MAE tiga random seed.

**A1 – Panjang jendela.** Jendela yang lebih panjang tidak selalu menaikkan akurasi. ANN mencapai validation MAE terendah, 212,4, pada $W = 6$, sedangkan RNN terbaik di $W = 48$ dengan 200,1. LSTM juga memilih $W = 6$ (validation MAE 227,1), dan GRU memilih $W = 48$ (206,7).

Khusus pada ANN, jendela panjang ikut menggemukkan jumlah parameter, jadi modelnya makin kompleks.

**A2 – Ukuran hidden.** Ukuran hidden terbaik berbeda dari satu arsitektur ke arsitektur lain. ANN, LSTM, dan GRU mencapai validation MAE terendah pada ukuran 128, masing-masing 233,8; 207,1; dan 188,7, sementara RNN terbaik di ukuran 64 dengan 207,2. Kapasitas yang lebih besar menolong sebagian arsitektur, tetapi peningkatannya tidak konsisten.

**A3 – Jumlah lapisan.** Satu lapisan sudah cukup untuk ANN, RNN, dan LSTM; hanya GRU yang paling baik dengan dua lapisan. Menambah lapisan tidak menjamin galat turun, sebab optimasi menjadi lebih sulit dan risiko overfitting naik.

**A4 – Learning rate.** ANN, RNN, dan GRU paling baik pada learning rate 0,001, sedangkan LSTM mencatat validation MAE terendah pada 0,01. Respons terhadap learning rate rupanya bergantung pada arsitektur dan pada cara tiap model menjalani optimasi.

**A5 – Kelompok fitur.** ANN paling baik dengan fitur net dan waktu, dengan validation MAE 246,0. RNN, LSTM, dan GRU justru memilih seluruh fitur. Fitur panggilan, SMS, dan waktu tampaknya memberi informasi tambahan, walau besar kontribusinya berbeda antararsitektur.

### C. Ablasi Pilihan

Ablasi pilihan menyentuh dua faktor: ukuran batch (*batch size*) dan *early stopping patience*. Keduanya diuji pada empat arsitektur, masing-masing dengan tiga *random seed*.

**B1 – Batch Size.** Ukuran batch yang diuji adalah 16, 64, dan 256. Batch 16 memberi rata-rata validation MAE terendah di semua model: 244,4 untuk ANN, 202,4 untuk RNN, 209,2 untuk LSTM, dan 202,3 untuk GRU. Ketika batch naik ke 256, angkanya memburuk menjadi 254,5, 228,3, 269,6, dan 233,8 secara berurutan. Pola ini cocok dengan dugaan bahwa batch kecil menghasilkan akurasi validasi yang lebih baik, dengan harga pembaruan parameter yang lebih banyak di setiap epoch.

**B5 – Early Stopping Patience.** Nilai patience yang diuji adalah 10, 30, dan 60. Patience 60 terbaik bagi ANN, LSTM, dan GRU, dengan validation MAE 241,8, 223,3, dan 205,6, sedangkan RNN justru terbaik pada patience 30 dengan 206,1. Temuan ini mendukung dugaan bahwa patience yang terlalu kecil menghentikan pelatihan sebelum model mencapai performa terbaiknya. Tapi memperbesar patience bukan jaminan perbaikan, karena lama pelatihan yang dibutuhkan tiap arsitektur tidak sama.

### D. Konfigurasi Terbaik

Peneliti menyusun konfigurasi terbaik tiap model dengan menggabungkan nilai hyperparameter yang memberi rata-rata validation MAE terendah di setiap eksperimen ablasi. Kombinasi itu dilatih ulang dengan tiga random seed, lalu dibandingkan dengan konfigurasi acuan di Duomo.

Hanya ANN yang membaik: validation MAE turun dari 248,9 ke 212,4, dan test MAE dari 309,9 ke 279,0. Ketiga model rekuren bergerak ke arah sebaliknya. Validation MAE RNN naik dari 206,1 ke 214,4 meski jumlah parameternya berkurang, LSTM naik dari 230,5 ke 234,6, dan GRU dari 207,5 ke 227,4.

Tabel III
HASIL GENERALISASI PADA CORSO COMO

| Model | Val MAE | | Test MAE | |
|---|---|---|---|---|
| | Acuan | Terbaik | Acuan | Terbaik |
| ANN | 157,7 | 154,2 | 149,2 | 129,2 |
| RNN | 139,0 | 142,8 | 127,8 | 133,9 |
| LSTM | 152,2 | 131,1 | 142,6 | 119,1 |
| GRU | 141,7 | 127,3 | 125,2 | **111,3** |

Data pengujian memberi gambaran yang tidak seragam. Konfigurasi gabungan RNN mencatat test MAE 242,2, sedangkan GRU 230,2. Galat di data pengujian rupanya tidak selalu mengikuti arah performa validasi.

Menggabungkan nilai terbaik dari setiap faktor tidak menjamin hasil yang lebih baik, kemungkinan karena hyperparameter saling berinteraksi. Konfigurasi gabungan karenanya harus dilatih ulang dan dibandingkan dengan konfigurasi acuan sebelum dipakai.

### E. Uji Generalisasi

Uji generalisasi dilakukan pada lokasi Corso Como menggunakan konfigurasi acuan dan konfigurasi gabungan yang sebelumnya diperoleh dari Duomo. Setiap konfigurasi dilatih ulang dengan tiga random seed tanpa mengubah nilai hyperparameter yang telah dipilih.

Berdasarkan Tabel III, konfigurasi terbaik meningkatkan performa pengujian ANN, LSTM, dan GRU, sedangkan RNN menunjukkan peningkatan kesalahan. Test MAE ANN turun dari 149,2 menjadi 129,2; LSTM dari 142,6 menjadi 119,1; dan GRU dari 125,2 menjadi 111,3. Sebaliknya, RNN mengalami kenaikan dari 127,8 menjadi 133,9.

Peringkat model juga berubah. Pada konfigurasi acuan, GRU menghasilkan Test MAE terendah sebesar 125,2, sedangkan pada konfigurasi gabungan GRU tetap menjadi model terbaik dengan Test MAE 111,3. Hasil ini menunjukkan bahwa manfaat pemilihan hyperparameter dari Duomo berbeda untuk setiap arsitektur ketika diterapkan pada Corso Como.

Pada periode Natal, seluruh konfigurasi mengalami peningkatan kesalahan dibandingkan periode pengujian reguler. GRU acuan menghasilkan MAE 273,9, sedangkan konfigurasi gabungannya menghasilkan MAE 316,2. Dengan demikian, konfigurasi yang unggul pada data pengujian reguler belum tentu lebih baik pada periode dengan karakteristik trafik berbeda.

## IV. PEMBAHASAN

Hasil eksperimen menunjukkan bahwa performa prediksi trafik seluler dipengaruhi oleh pemilihan arsitektur dan hyperparameter. Pada konfigurasi acuan, RNN menghasilkan validation MAE terendah sebesar 206,1, sedangkan ANN memperoleh nilai 248,9. Hal ini menunjukkan bahwa kemampuan memproses urutan temporal dapat memberikan keuntungan dibandingkan penggunaan masukan yang diratakan, meskipun

arsitektur rekuren yang lebih kompleks seperti LSTM dan GRU tidak selalu lebih unggul.

Pengaruh hyperparameter berbeda menurut arsitektur. Panjang jendela yang lebih besar tidak selalu meningkatkan akurasi karena informasi historis tambahan belum tentu relevan terhadap prediksi. Ukuran hidden memberikan peningkatan cukup nyata pada beberapa model, khususnya GRU yang mencapai validation MAE 188,7 pada hidden 128. Sebaliknya, penambahan lapisan tidak secara konsisten menghasilkan performa lebih baik. Faktor learning rate dan kelompok fitur juga menunjukkan bahwa konfigurasi optimal bergantung pada karakteristik setiap model.

Pada eksperimen batch size, seluruh arsitektur memperoleh validation MAE terendah ketika menggunakan batch 16. Sementara itu, patience yang lebih besar cenderung memberikan kesempatan pelatihan lebih lama, tetapi tidak selalu meningkatkan akurasi. Variasi antar seed turut memengaruhi hasil, sehingga penggunaan rata-rata dan simpangan baku dari tiga seed penting untuk menghindari kesimpulan berdasarkan satu percobaan saja.

Penggabungan hyperparameter terbaik secara individual ternyata hanya meningkatkan performa validasi ANN, sedangkan RNN, LSTM, dan GRU tidak menunjukkan peningkatan dibandingkan konfigurasi acuannya. Temuan ini mengindikasikan kemungkinan adanya interaksi antarhyperparameter yang tidak tercakup dalam eksperimen ablasi satu faktor. Selain itu, jumlah parameter yang lebih besar tidak selalu berkaitan dengan MAE yang lebih rendah.

Studi ini memiliki beberapa keterbatasan, yaitu cakupan data yang terbatas pada satu kota, periode pelatihan sekitar empat minggu, hanya tiga random seed, dan satu pembagian data secara kronologis. Oleh karena itu, hasil penelitian belum dapat digeneralisasi ke seluruh jaringan telekomunikasi tanpa pengujian tambahan pada periode dan lokasi yang lebih beragam.

## V. Kesimpulan

Penelitian ini berhasil membandingkan ANN, RNN, LSTM, dan GRU melalui 348 percobaan prediksi trafik seluler per jam. Pada konfigurasi acuan di Duomo, RNN menghasilkan test MAE terendah sebesar 229,6, sedangkan ANN, LSTM, dan GRU masing-masing memperoleh 309,9, 273,6, dan 237,2.

Studi ablasi menunjukkan bahwa panjang jendela, ukuran hidden, batch size, dan faktor optimasi memengaruhi performa secara berbeda pada setiap arsitektur. Batch size 16 menghasilkan validation MAE terendah pada seluruh model dalam pengujian B1.

Penggabungan hyperparameter pilihan meningkatkan performa ANN dengan menurunkan validation MAE dari 248,9 menjadi 212,4, tetapi tidak meningkatkan performa validasi ketiga model rekuren dibandingkan konfigurasi acuan.

Hasil tersebut menunjukkan bahwa model yang lebih kompleks dan kombinasi hyperparameter terbaik secara individual tidak selalu menghasilkan prediksi paling akurat. Pemilihan konfigurasi tetap perlu mempertimbangkan performa validasi, kestabilan hasil, dan karakteristik data.

Pada uji generalisasi di Corso Como, konfigurasi gabungan meningkatkan performa pengujian ANN, LSTM, dan GRU, dengan test MAE masing-masing sebesar 129,2; 119,1; dan 111,3. Sebaliknya, RNN mengalami peningkatan test MAE dari 127,8 menjadi 133,9. GRU memperoleh performa pengujian terbaik, tetapi mengalami kenaikan MAE pada periode Natal dari 273,9 menjadi 316,2. Temuan ini menunjukkan bahwa konfigurasi optimal bergantung pada lokasi dan periode evaluasi.

## Kontribusi Anggota

Helsa Anastasya (124400009) mengerjakan seluruh tahapan tugas secara individu, meliputi persiapan data, pelaksanaan eksperimen ablasi, evaluasi model ANN, RNN, LSTM, dan GRU, analisis hasil, serta penyusunan laporan.

## Pernyataan Penggunaan AI

Penulis menggunakan ChatGPT dan Claude AI sebagai alat bantu untuk memahami instruksi tugas, mengatasi kesalahan teknis pada JupyterLab, memberikan panduan pelaksanaan eksperimen, serta membantu penyusunan laporan. Seluruh hasil eksperimen dan nilai evaluasi diperoleh dari eksekusi kode Python pada dataset yang ditentukan dalam tugas.

## Kode dan Data

Kode, notebook beserta output, dan seluruh hasil run tersedia di https://github.com/username/nama-repo.

## Pustaka


[1] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.

[2] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio, "Learning phrase representations using RNN encoder–decoder for statistical machine translation," in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2014, pp. 1724–1734.

[3] G. Barlacchi, M. De Nadai, R. Larcher, A. Casella, C. Chitic, G. Torrisi, F. Antonelli, A. Vespignani, A. Pentland, and B. Lepri, "A multi-source dataset of urban life in the city of Milan and the Province of Trentino," *Scientific Data*, vol. 2, p. 150055, 2015.

[4] C. Zhang, S. Dang, B. Shihada, and M.-S. Alouini, "Dual attention-based federated learning for wireless traffic prediction," in *IEEE INFOCOM 2021 – IEEE Conference on Computer Communications*, 2021, pp. 1–10.